



CAMPUS BIRIGUI

RELATÓRIO FINAL

JOÃO EDUARDO SANTO FARIAS

PROF. DR. MURILO VARGES DA SILVA


DEZEMBRO DE 2023

Relatório de Atividades no Semestre - Processamento Digital de Imagens (PDI)

Este relatório destaca as atividades e aprendizados adquiridos ao longo do semestre no curso de Processamento Digital de Imagens.

Código Python e Imagem - Iniciais do Nome

No início do semestre, o foco foi na implementação prática de algoritmos de PDI usando Python. A atividade de escrever código para plotar pontos representando meu nome próprio proporcionou uma compreensão prática de conceitos fundamentais, incluindo leitura de imagens e manipulação de pixels. Essa experiência inicial estabeleceu a base para explorar conceitos mais avançados ao longo do curso.



Fundamentos

Entre essas operações, destacam-se as operações ponto a ponto, por vizinhança e as transformações geométricas.

As operações ponto a ponto consistem em realizar modificações nos pixels de uma imagem de maneira individual, sem levar em consideração a relação com os pixels vizinhos. Essas operações são simples, mas fundamentais para ajustar características locais da imagem, como brilho e contraste. Compreender como essas operações afetam cada pixel é crucial para o entendimento global do PDI.

As operações por vizinhança, por sua vez, envolvem a consideração da relação entre um pixel e seus vizinhos ao aplicar uma transformação. Essas operações são mais complexas e permitem ajustes mais refinados, sendo frequentemente utilizadas em técnicas de suavização, realce de bordas e detecção de padrões. Explorar essas operações proporciona uma compreensão mais

profunda de como as informações contextuais influenciam as modificações na imagem.

As transformações geométricas, abordadas nesse tema, incluem operações como translação, rotação, escala e outras transformações que alteram a geometria da imagem. Essas transformações são cruciais em aplicações como reconhecimento de padrões, correção de distorções e alinhamento de imagens. A prática dessas transformações em imagens reais ajuda a visualizar como as alterações geométricas afetam a percepção e interpretação da informação visual.

As atividades práticas associadas ao tema Fundamentos foram essenciais para consolidar o entendimento teórico adquirido. A aplicação prática de operações ponto a ponto, operações por vizinhança e transformações geométricas em imagens reais proporcionou uma experiência valiosa. Isso não apenas fortaleceu a compreensão dos conceitos teóricos, mas também permitiu explorar as potencialidades e limitações dessas operações em cenários do mundo real.

Em resumo, o tema Fundamentos desempenhou um papel crucial ao estabelecer as bases do conhecimento em PDI. A compreensão dessas operações fundamentais é vital para o desenvolvimento de abordagens mais avançadas e a aplicação eficaz dessas técnicas em diversas áreas, desde o pré-processamento de imagens até a análise de padrões e reconhecimento de objetos.

Transformações Intensidade:

Essas transformações são aplicadas globalmente a cada pixel, sem considerar a vizinhança, e têm o objetivo de ajustar o contraste, brilho e outras características globais da imagem.

Uma transformação básica de intensidade é a chamada transformação linear, representada por $g(x, y) = \alpha * f(x, y) + \beta$, onde $f(x, y)$ é a intensidade original do pixel e $g(x, y)$ é a intensidade após a transformação. Os parâmetros α e β permitem ajustar a inclinação e o deslocamento da reta que representa a transformação, impactando o contraste e brilho, respectivamente.

Outra transformação comum é a transformação de potência ($g(x, y) = c * [f(x, y)]^\gamma$), onde γ controla a forma da transformação. Para $\gamma > 1$, a transformação realça as regiões de intensidade mais baixa, enquanto para $\gamma < 1$, as regiões de intensidade mais alta são realçadas. Isso é útil para ajustar o contraste de diferentes partes da imagem.

Além disso, as transformações logarítmicas ($g(x, y) = c * \log[1 + f(x, y)]$) são frequentemente empregadas para expandir as faixas de intensidade mais baixas, realçando detalhes em áreas mais escuras da imagem.

A equalização de histograma é outra transformação essencial, ajustando a distribuição de intensidades da imagem para melhor utilizar todo o intervalo disponível. Esse processo aumenta o contraste global, destacando detalhes e tornando a imagem mais perceptível.

Na prática, bibliotecas como OpenCV oferecem funções para aplicar essas transformações de intensidade de maneira eficiente. Essas operações são valiosas em diversas aplicações, incluindo aprimoramento de imagens para melhorar a visualização de detalhes, preparação de dados para algoritmos de análise de imagem e correção de características globais da imagem para torná-la mais adequada a determinados contextos. Em resumo, as transformações de intensidade desempenham um papel essencial no ajuste global das características de uma imagem, tornando-a mais adaptada às necessidades específicas de uma aplicação.



Filtragem Espacial:

Essa abordagem se diferencia da filtragem no domínio da frequência, focalizando-se na manipulação direta dos pixels da imagem original.

Uma operação fundamental na filtragem espacial é a convolução, na qual uma máscara, também conhecida como kernel, é deslizada sobre a imagem original, multiplicando os valores dos pixels pela máscara e somando os resultados. A escolha da máscara determina a natureza da filtragem, sendo comumente utilizadas máscaras como média, gaussiana, laplaciana, Sobel (horizontal e vertical), gradiente (combinação de Sobel horizontal e vertical) e outras, dependendo dos efeitos desejados.


A aplicação prática dessas máscaras permite alcançar diferentes objetivos. Máscaras de média, por exemplo, têm o efeito de suavizar a imagem, removendo detalhes finos e reduzindo a presença de ruídos. Máscaras gaussianas proporcionam uma suavização mais controlada, preservando melhor as bordas. Já máscaras laplacianas são comumente utilizadas para realçar bordas e detalhes.

As máscaras de Sobel e gradiente são especialmente eficazes na detecção de bordas em imagens, destacando as transições de intensidade. Essas operações são fundamentais em tarefas como detecção de contornos e análise de gradientes em imagens. Além disso, a filtragem espacial pode envolver a combinação de máscaras, como na aplicação de um filtro laplaciano somado à imagem original, resultando em um realce mais pronunciado de características de interesse.

Para implementações práticas, bibliotecas como OpenCV e funções como `convolve` em `scipy` são frequentemente utilizadas, facilitando a aplicação de operações de filtragem espacial em diversas imagens de teste, como Lena, Biel, e Cameraman. Em resumo, a filtragem espacial é uma técnica versátil e poderosa, permitindo ajustar a intensidade dos pixels de uma imagem de maneira localizada e eficaz para diversas aplicações em processamento de imagens digitais.

Imagem automática/Manual

Lena



Lena



Transformada de Fourier

A Transformada de Fourier é uma ferramenta matemática fundamental que desempenha um papel essencial em diversas áreas, como processamento de sinais, processamento de imagens, análise de espectro e muitas outras aplicações em ciência e engenharia. Em Python, a Transformada de Fourier pode ser implementada com facilidade, graças ao suporte de bibliotecas como NumPy e SciPy.

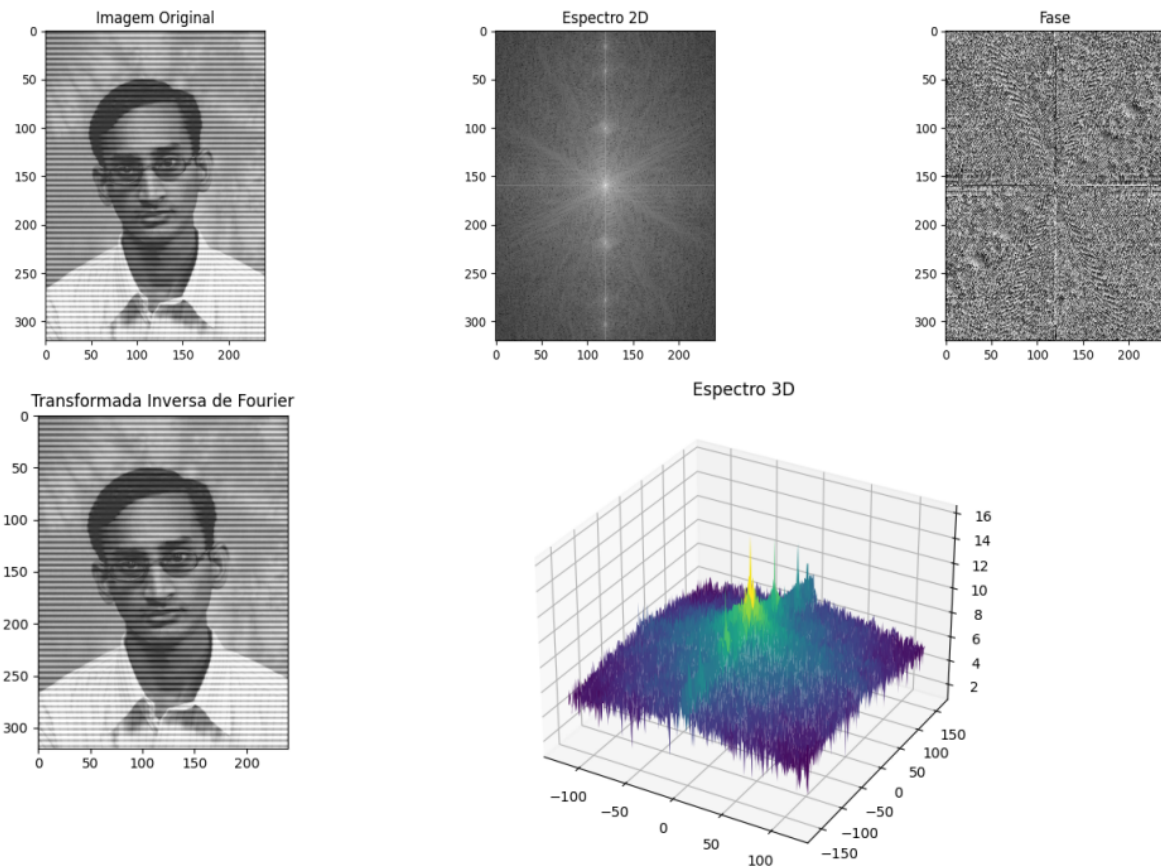
Essa técnica permite a decomposição de um sinal ou imagem em suas componentes de frequência, revelando informações cruciais sobre sua composição espectral. Ela é amplamente utilizada em áreas como processamento de áudio, análise de séries temporais, processamento de imagens médicas, comunicações, entre outras.

Primeiro, uma imagem é carregada a partir do caminho especificado e convertida para escala de cinza, se necessário. A imagem original é então exibida em um gráfico 2D em escala de cinza.

Em seguida, a Transformada de Fourier 2D é aplicada à imagem original usando a função `fft2` da biblioteca SciPy. Isso calcula o espectro de frequência da imagem. O logaritmo do valor absoluto do espectro é calculado para realçar os detalhes e evitar valores muito altos. O resultado é exibido como um gráfico 2D do espectro.

A fase da Transformada de Fourier é calculada usando `np.angle` e exibida como um terceiro gráfico 2D, representando a fase da imagem. A Transformada Inversa de Fourier é calculada com `ifft2` para recuperar a imagem original a partir do espectro de frequência.

Finalmente, o código também inclui a plotagem do espectro em 3D usando `matplotlib`, onde o espectro é projetado em um espaço tridimensional para visualizar sua estrutura de frequência. Isso é útil para analisar as componentes de frequência da imagem.



Desafio Stanford:


Verificação de defeitos em placas:

A detecção de defeitos em placas é uma tarefa crucial no controle de qualidade de processos de fabricação. Para realizar essa verificação de forma eficaz, empregamos uma abordagem que envolve a comparação entre duas imagens: uma representando uma placa sem defeito e outra, uma placa com defeito. A essência desse método reside na realização de uma operação de subtração entre as duas imagens, permitindo-nos identificar discrepâncias que indicam potenciais defeitos.

Ao subtrair a imagem da placa sem defeito da imagem da placa com defeito, obtemos uma representação visual das diferenças entre elas. Essas diferenças podem incluir imperfeições, fissuras ou quaisquer outros desvios do padrão esperado. Para realçar essas discrepâncias, aplicamos um limiar, que destaca as regiões onde as diferenças são significativas.

Além disso, utilizamos a detecção de contornos para identificar e mapear áreas específicas que indicam a presença de defeitos. Isso nos permite não apenas

encontrar defeitos, mas também quantificá-los e visualizá-los em destaque na imagem da placa com defeito, facilitando a análise e tomada de decisões no processo de controle de qualidade.



Essa abordagem eficiente e visualmente informativa oferece uma maneira confiável de identificar e avaliar defeitos em placas durante o processo de fabricação, contribuindo para a melhoria contínua da qualidade e a redução de resíduos.

Deteção de movimento:

É possível detectar movimentos em vídeos usando Python através da subtração do plano de fundo da cena, identificando variações significativas nas imagens. Essa técnica é valiosa para diversas aplicações, como vigilância por vídeo, controle de qualidade e muito mais. O Python, com bibliotecas como OpenCV, oferece uma abordagem eficaz para a detecção de movimentos, destacando as regiões em que ocorrem mudanças, independentemente da presença de pessoas. Isso permite uma análise automatizada de vídeos em busca de eventos de interesse, contribuindo para uma variedade de aplicações práticas.



Filtragem Domínio Frequência


Essa abordagem baseia-se na análise do espectro de frequência da imagem, geralmente utilizando transformações matemáticas como a Transformada de Fourier, que converte a representação da imagem do domínio espacial para o domínio da frequência.

Dois tipos principais de filtros são empregados nessa abordagem: os filtros passa-baixa e os passa-alta. Os filtros passa-baixa permitem a passagem de baixas frequências enquanto atenuam ou eliminam frequências mais altas. São úteis para suavizar uma imagem, eliminando ruídos de alta frequência ou detalhes finos. Em contrapartida, os filtros passa-alta permitem a passagem de altas frequências enquanto atenuam ou eliminam frequências mais baixas, sendo eficazes para realçar bordas e detalhes finos em uma imagem.

Os parâmetros desses filtros, notadamente o raio do corte (D_0) em filtros passa-baixa e passa-alta, desempenham um papel crucial. Um pequeno D_0 preserva principalmente baixas frequências, resultando em uma imagem suavizada, enquanto um D_0 moderado permite uma faixa mais ampla de frequências, proporcionando mais detalhes. Um D_0 grande permite a passagem de uma ampla faixa de frequências, mantendo a maioria dos detalhes da imagem original.

Na prática, esses filtros têm diversas aplicações. Filtros passa-baixa são frequentemente utilizados para remover ruído, suavizando imagens. Por outro lado, filtros passa-alta são eficazes para realçar detalhes importantes, como bordas e características de alta frequência. Além disso, a aplicação desses filtros no pré-processamento é valiosa em contextos nos quais a qualidade da imagem influencia diretamente algoritmos subsequentes, como em sistemas de reconhecimento de padrões. Essa abordagem no domínio da frequência oferece,

assim, uma ferramenta poderosa e versátil para ajustar características específicas de uma imagem de acordo com os requisitos da aplicação.



Morfologia

Duas operações morfológicas fundamentais são a erosão e a dilatação. A erosão reduz o tamanho dos objetos na imagem, eliminando pixels nas bordas externas. Isso é útil para remover detalhes finos, separar objetos próximos e simplificar a forma dos objetos. Por outro lado, a dilatação aumenta o tamanho dos objetos, adicionando pixels às bordas externas. Essa operação é valiosa para preencher lacunas, unir objetos próximos e realçar características.

Essas operações são realizadas com o auxílio de elementos estruturantes, que são padrões ou formas que definem a vizinhança utilizada nas operações morfológicas. O elemento estruturante pode ser uma matriz pequena, normalmente quadrada, com pixels definidos como 0 ou 1. A forma do elemento estruturante influencia diretamente o resultado das operações morfológicas.

Além da erosão e dilatação, a morfologia também inclui operações combinadas, como abertura e fechamento. A abertura é a combinação de erosão seguida por dilatação, útil para remover ruídos pequenos e "abrir" lacunas entre objetos. Por sua vez, o fechamento é a combinação de dilatação seguida por erosão, sendo útil para preencher pequenas lacunas e "fechar" buracos na imagem.

Uma técnica avançada na morfologia é a Transformada Hit-or-Miss, que combina erosões utilizando dois elementos estruturantes. Essa técnica é particularmente útil para a detecção de características complexas na imagem.